

# 確率・統計基礎: サノフの定理、KL ダイバージェンス

森 立平

## 経験分布の集中

大数の法則や中心極限定理と同様に i.i.d. 確率変数  $X_1, X_2, \dots, X_N$  を考える。

確率変数  $X$  の像が有限集合  $A = \{1, 2, \dots, m\}$  とする。

任意の  $\mathbf{x} \in A^N$  と各  $k \in A$  について  
 $N_k(\mathbf{x}) := \{t \in \{1, \dots, N\} \mid x_t = k\}$  とおく。

$\hat{P}_{\mathbf{x}} := \left( \frac{N_k(\mathbf{x})}{N} \right)_{k \in A}$  を経験分布という。

サイコロを 100 回振って 1, 2, 3, 4, 5, 6 がそれぞれ 16, 13, 18, 20, 14, 19 回出たとき経験分布は

$$\hat{P}_{\mathbf{x}} := \left( \frac{16}{100}, \frac{13}{100}, \frac{18}{100}, \frac{20}{100}, \frac{14}{100}, \frac{19}{100} \right).$$

# 経験分布

有限集合  $A = \{1, 2, \dots, m\}$  とする。

$\mathcal{P} := \{(p_1, \dots, p_m) \in \mathbb{R}_{\geq 0}^m \mid p_1 + \dots + p_m = 1\}$ .

## Definition

任意の  $N \in \mathbb{Z}_{>0}$  について

$$\mathcal{P}_N := \left\{ \left( \frac{N_1}{N}, \frac{N_2}{N}, \dots, \frac{N_m}{N} \right) \mid \begin{array}{l} (N_1, \dots, N_m) \in \mathbb{Z}_{\geq 0}^m \\ N_1 + N_2 + \dots + N_m = N \end{array} \right\}$$

とする。任意の  $\mathbf{x} \in A^N$  について、経験分布  $\hat{P}_{\mathbf{x}} \in \mathcal{P}_N$  は

$$\hat{P}_{\mathbf{x}} := \left( \frac{\hat{N}_1(\mathbf{x})}{N}, \frac{\hat{N}_2(\mathbf{x})}{N}, \dots, \frac{\hat{N}_m(\mathbf{x})}{N} \right).$$

ここで  $k = 1, 2, \dots, m$  について  $\hat{N}_k(\mathbf{x}) := \#\{t \in \{1, \dots, N\} \mid x_t = k\}$ .

## Example ( $m = 2$ のとき)

$$\mathcal{P}_3 = \left\{ \left( \frac{0}{3}, \frac{3}{3} \right), \left( \frac{1}{3}, \frac{2}{3} \right), \left( \frac{2}{3}, \frac{1}{3} \right), \left( \frac{3}{3}, \frac{0}{3} \right) \right\}$$

$$\hat{P}_{12211} = \left( \frac{3}{5}, \frac{2}{5} \right)$$

## 多項分布

### Definition (カテゴリ分布)

$p \in \mathcal{P}$  について、 $X \sim \text{Cat}(p) \stackrel{\text{def}}{\iff}$

$$\Pr(X = k) = p_k \quad \text{for } k \in \{1, 2, \dots, m\}.$$

カテゴリ分布において、 $X$  の像自体は気にしないことが多く、数ではなくてアルファベット  $A, B, C, \dots$  などでもよい。

### Definition (多項分布)

$p \in \mathcal{P}$  について、 $X \sim \text{Multinom}(p, N) \stackrel{\text{def}}{\iff}$

$$\Pr(X = (N_1, \dots, N_m)) = \binom{N}{N_1 \ N_2 \ \dots \ N_m} \prod_{k=1}^m p_k^{N_k}$$

が  $(N_1, \dots, N_m) \in \mathbb{Z}_{\geq 0}^m$  で  $N_1 + \dots + N_m = N$  であるものについて成り立つ。

# 多項分布と経験分布

## Lemma

$p \in \mathcal{P}$  とする。  $X_1, \dots, X_N$  が *i.i.d.* で  $\text{Cat}(p)$  に従うとする。このとき、 $\mathbf{X} := (X_1, X_2, \dots, X_N)$  について  $N\hat{P}_{\mathbf{X}} \sim \text{Multinom}(p, N)$ .

## Proof.

$(N_1, \dots, N_m) \in \mathbb{Z}_{\geq 0}^m$  で  $N_1 + \dots + N_m = N$  であるものについて

$$\Pr(N\hat{P}_{\mathbf{X}} = (N_1, \dots, N_m)) = \binom{N}{N_1 N_2 \dots N_m} \prod_{k=1}^m p_k^{N_k}$$

を示せばよい。

$$\begin{aligned} \Pr(N\hat{P}_{\mathbf{X}} = (N_1, \dots, N_m)) &= \Pr((\hat{N}_1(\mathbf{X}), \dots, \hat{N}_m(\mathbf{X})) = (N_1, \dots, N_m)) \\ &= \sum_{\substack{\mathbf{x} \in A^N \\ (\hat{N}_1(\mathbf{x}), \dots, \hat{N}_m(\mathbf{x})) = (N_1, \dots, N_m)}} \Pr(\mathbf{X} = \mathbf{x}) \\ &= \frac{N!}{(N_1!) (N_2!) \dots (N_m!)} \prod_{k=1}^m p_k^{N_k}. \end{aligned}$$



# Kullback–Leibler divergence

## Definition (Kullback–Leibler divergence)

$D: \mathcal{P} \times \mathcal{P} \rightarrow \mathbb{R}$  を以下で定義する

$$D(q \parallel p) := \sum_{k=1}^m q_k \log \frac{q_k}{p_k}.$$

ただし、 $0 \log 0 = 0 \log \frac{0}{0} = 0$  とし、 $q \log \frac{q}{0}$  は  $q > 0$  について  $+\infty$  とする。

# イェンセンの不等式

## Lemma (イェンセンの不等式)

凸関数  $f: \mathbb{R} \rightarrow \mathbb{R}$  と確率変数  $X: \Omega \rightarrow \mathbb{R}$  について、

$$\mathbb{E}[f(X)] \geq f(\mathbb{E}[X]).$$

### $X$ の像が有限のときの証明.

確率変数  $X$  は  $k = 1, 2, \dots, m$  について確率  $p_k$  で値  $a_k$  をとると仮定する。 $m$  についての帰納法で示す。 $m = 1$  のときは明らかに成り立つ。 $X$  の像のサイズが  $m$  未満のときにイェンセンの不等式が成り立つと仮定する。

$$\begin{aligned}\mathbb{E}[f(X)] &= \sum_{k=1}^m p_k f(a_k) = \left( \sum_{k=1}^{m-1} p_k \right) \sum_{k=1}^{m-1} \frac{p_k}{\sum_{\ell=1}^{m-1} p_\ell} f(a_k) + p_m f(a_m) \\ &\geq \left( \sum_{k=1}^{m-1} p_k \right) f \left( \sum_{k=1}^{m-1} \frac{p_k}{\sum_{\ell=1}^{m-1} p_\ell} a_k \right) + p_m f(a_m) \quad (\text{帰納法の仮定}) \\ &\geq f \left( \left( \sum_{k=1}^{m-1} p_k \right) \sum_{k=1}^{m-1} \frac{p_k}{\sum_{\ell=1}^{m-1} p_\ell} a_k + p_m a_m \right) \quad (f \text{ の凸性}) \\ &\geq f \left( \sum_{k=1}^m p_k a_k \right) = f(\mathbb{E}[X]).\end{aligned}$$

□

# KL-divergence の性質

## Lemma

任意の  $p, q \in \mathcal{P}$  について  $D(q \parallel p) \geq 0$ .

## Proof.

$$\begin{aligned} D(q \parallel p) &= \sum_{k=1}^m q_k \log \frac{q_k}{p_k} \\ &= - \sum_{k=1}^m q_k \log \frac{p_k}{q_k} \\ &\geq - \log \sum_{k=1}^m q_k \frac{p_k}{q_k} \quad (\text{イエンセンの不等式}) \\ &= 0. \end{aligned}$$





# サノフの定理

## Theorem (サノフの定理)

任意の  $\Gamma \subseteq \mathcal{P}$  について

$$\frac{1}{N} \log \Pr(\hat{P}_X \in \Gamma) \leq - \inf_{q \in \Gamma} D(q \| p) + \frac{m \log(N+1)}{N} \quad \text{for any } N \in \mathbb{Z}_{>0}$$

$$\liminf_{N \rightarrow \infty} \frac{1}{N} \log \Pr(\hat{P}_X \in \Gamma) \geq - \inf_{q \in \Gamma^\circ} D(q \| p).$$

ただし、 $\Gamma^\circ$  は  $\Gamma$  の内点の集合とする。

# 特定の経験分布になる確率の上下界 1/3

## Lemma

任意の  $q \in \mathcal{P}_N$  について

$$\frac{1}{(N+1)^m} e^{-ND(q\|p)} \leq \Pr(\hat{P}_X = q) \leq e^{-ND(q\|p)}.$$

## Proof.

任意の  $k$  について  $p_k > 0$  と仮定して一般性を失わない。  $0^0 = 1$  とすると

$$\begin{aligned}\Pr(\hat{P}_X = q) &= \binom{N}{Nq_1 Nq_2 \cdots Nq_m} \prod_{k=1}^m p_k^{Nq_k} \\ &= \binom{N}{Nq_1 Nq_2 \cdots Nq_m} \prod_{k=1}^m q_k^{Nq_k} \prod_{k=1}^m \frac{p_k^{Nq_k}}{q_k^{Nq_k}} \\ &= \Pr(\hat{P}_Y = q) \prod_{k=1}^m \left(\frac{p_k}{q_k}\right)^{Nq_k} \\ &= \Pr(\hat{P}_Y = q) e^{-ND(q\|p)}.\end{aligned}$$

ここで  $Y$  は  $\text{Cat}(q)$  に従う確率変数。



## 特定の経験分布になる確率の上下界 2/3

### Lemma

任意の  $q \in \mathcal{P}_N$  について

$$\frac{1}{(N+1)^m} e^{-ND(q\|p)} \leq \Pr(\hat{P}_X = q) \leq e^{-ND(q\|p)}$$

### Proof.

$$\Pr(\hat{P}_X = q) = \Pr(\hat{P}_Y = q) e^{-ND(q\|p)}.$$

よって  $\frac{1}{(N+1)^m} \leq \Pr(\hat{P}_Y = q) \leq 1$  を示せばよいが上界は明らか。

任意の  $p' \in \mathcal{P}_N$  について

$$\Pr(\hat{P}_Y = p') \leq \Pr(\hat{P}_Y = q)$$

が成り立つと仮定する (後で証明する) と、

$$1 = \sum_{p' \in \mathcal{P}_N} \Pr(\hat{P}_Y = p') \leq \sum_{p' \in \mathcal{P}_N} \Pr(\hat{P}_Y = q) = |\mathcal{P}_N| \Pr(\hat{P}_Y = q)$$

であるが  $|\mathcal{P}_N| = \binom{N+m-1}{m-1} \leq (N+1)^m$  より下界を得る。

□

## 特定の経験分布になる確率の上下界 3/3

最後に

$$\Pr(\hat{R}_Y = p') \leq \Pr(\hat{R}_Y = q)$$

を示せばよい。

$$\begin{aligned}\Pr(\hat{R}_Y = p') &= \binom{N}{Np'_1 Np'_2 \cdots Np'_m} \prod_{k=1}^m q_k^{Np'_k} \\ \Pr(\hat{R}_Y = q) &= \binom{N}{Nq_1 Nq_2 \cdots Nq_m} \prod_{k=1}^m q_k^{Nq_k}\end{aligned}$$

より

$$\begin{aligned}\frac{\Pr(\hat{R}_Y = p')}{\Pr(\hat{R}_Y = q)} &= \prod_{k=1}^m \frac{(Nq_k)!}{(Np'_k)!} q_k^{Np'_k - Nq_k} \\ &\leq \prod_{k=1}^m (Nq_k)^{Nq_k - Np'_k} q_k^{Np'_k - Nq_k} \quad \left( \frac{b!}{a!} \leq b^{b-a} \right) \\ &= \prod_{k=1}^m N^{Nq_k - Np'_k} \\ &= 1.\end{aligned}$$

# サノフの定理の上界の証明

## Theorem (サノフの定理)

任意の  $\Gamma \subseteq \mathcal{P}$  について

$$\frac{1}{N} \log \Pr(\hat{P}_X \in \Gamma) \leq - \inf_{q \in \Gamma} D(q \| p) + \frac{m \log(N+1)}{N} \quad \text{for any } N \in \mathbb{Z}_{>0}$$

$$\liminf_{N \rightarrow \infty} \frac{1}{N} \log \Pr(\hat{P}_X \in \Gamma) \geq - \inf_{q \in \Gamma^\circ} D(q \| p).$$

ただし、 $\Gamma^\circ$  は  $\Gamma$  の内点の集合とする。

## 上界の証明.

任意の  $\Gamma \subseteq \mathcal{P}$  と  $N \in \mathbb{Z}_{>0}$  について

$$\begin{aligned} \Pr(\hat{P}_X \in \Gamma) &= \sum_{q \in \Gamma \cap \mathcal{P}_N} \Pr(\hat{P}_X = q) \\ &\leq |\Gamma \cap \mathcal{P}_N| \max_{q \in \Gamma \cap \mathcal{P}_N} \Pr(\hat{P}_X = q) \\ &\leq (N+1)^m \max_{q \in \Gamma \cap \mathcal{P}_N} e^{-ND(q \| p)} \\ &\leq (N+1)^m \sup_{q \in \Gamma} e^{-ND(q \| p)} \\ &= (N+1)^m e^{-N \inf_{q \in \Gamma} D(q \| p)}. \end{aligned}$$

# サノフの定理の下界の証明 1/2

## Theorem (サノフの定理)

任意の  $\Gamma \subseteq \mathcal{P}$  について

$$\frac{1}{N} \log \Pr(\hat{P}_X \in \Gamma) \leq - \inf_{q \in \Gamma} D(q \| p) + \frac{m \log(N+1)}{N} \quad \text{for any } N \in \mathbb{Z}_{>0}$$

$$\liminf_{N \rightarrow \infty} \frac{1}{N} \log \Pr(\hat{P}_X \in \Gamma) \geq - \inf_{q \in \Gamma^\circ} D(q \| p).$$

ただし、 $\Gamma^\circ$  は  $\Gamma$  の内点の集合とする。

## 下界の証明 1/2.

任意の  $\Gamma \subseteq \mathcal{P}$  と  $N \in \mathbb{Z}_{>0}$  について

$$\begin{aligned} \Pr(\hat{P}_X \in \Gamma) &= \sum_{q \in \Gamma \cap \mathcal{P}_N} \Pr(\hat{P}_X = q) \\ &\geq \max_{q \in \Gamma \cap \mathcal{P}_N} \Pr(\hat{P}_X = q) \\ &\geq \max_{q \in \Gamma \cap \mathcal{P}_N} \frac{1}{(N+1)^m} e^{-ND(q \| p)} \\ &\geq \frac{1}{(N+1)^m} e^{-N \min_{q \in \Gamma \cap \mathcal{P}_N} D(q \| p)}. \end{aligned}$$

## サノフの定理の下界の証明 2/2

示したいことは

$$\liminf_{N \rightarrow \infty} \frac{1}{N} \log \Pr(\hat{P}_X \in \Gamma) \geq - \inf_{q \in \Gamma^\circ} D(q \| p).$$

今示せたことは

$$\frac{1}{N} \log \Pr(\hat{P}_X \in \Gamma) \geq - \min_{q \in \Gamma \cap \mathcal{P}_N} D(q \| p) - \frac{m \log(N+1)}{N}.$$

よって任意の  $\Gamma \subseteq \mathcal{P}$  について以下を示せばよい。

$$\liminf_{N \rightarrow \infty} - \min_{q \in \Gamma \cap \mathcal{P}_N} D(q \| p) = - \limsup_{N \rightarrow \infty} \min_{q \in \Gamma \cap \mathcal{P}_N} D(q \| p) \geq - \inf_{q \in \Gamma^\circ} D(q \| p).$$

inf の定義より、任意の  $\epsilon > 0$  について、ある  $q_\epsilon \in \Gamma^\circ$  が存在して、  
 $D(q_\epsilon \| p) \leq \inf_{q \in \Gamma^\circ} D(q \| p) + \epsilon$ .

- ▶ KL divergence の連続性より、任意の  $q \in \mathcal{P}$  と  $\epsilon > 0$  について、ある  $\delta_{q,\epsilon}$  が存在して、 $|D(q \| p) - D(q' \| p)| < \epsilon$  が任意の  $q' \in S_{q,\delta_{q,\epsilon}} := \{q' \in \mathcal{P} \mid \|q - q'\| < \delta_{q,\epsilon}\}$  について成り立つ。ここで  $\|\cdot\|$  はユークリッドノルム (任意のノルムでよい)。
- ▶  $\Gamma^\circ$  は開集合なので、任意の  $q \in \Gamma^\circ$  についてある  $\tau_q$  が存在して、 $S_{q,\tau_q} \subseteq \Gamma^\circ$ 。

よって、 $\delta := \min \left\{ \delta_{q_\epsilon, \frac{\epsilon}{2}}, \tau_{q_\epsilon} \right\}$  とすると、任意の  $\epsilon > 0$  と  $q' \in S_{q_\epsilon, \delta} \subseteq \Gamma^\circ$  について

$$- \inf_{q \in \Gamma^\circ} D(q \| p) \leq -D\left(q_\epsilon \| p\right) + \frac{\epsilon}{2} \leq -D(q' \| p) + \epsilon \leq - \min_{q \in \Gamma \cap \mathcal{P}_N} D(q \| p) + \epsilon$$

が十分大きな  $N$  について成り立つ。両辺  $\liminf_{N \rightarrow \infty}$  を取ることで不等式を得る。

## 二項分布 ( $m = 2$ ) の場合

二項分布の場合  $\sum_{k=1}^n X_k = N_1(\mathbf{X})$  であり、 $\hat{P}_{\mathbf{X}} = \left( \frac{N - N_1(\mathbf{X})}{N}, \frac{N_1(\mathbf{X})}{N} \right)$  と一対一に対応する ( $A = \{1, 2\}$  ではなくて、 $A = \{0, 1\}$  としている)。

$$\Pr\left(\sum_{k=1}^N X_k \geq Na\right) = \Pr\left(\frac{N_1(\mathbf{X})}{N} \geq a\right)$$

$\Gamma := \{(p_0, p_1) \mid p_1 \geq a\}$  とすると、

$$\Pr\left(\sum_{k=1}^N X_k \geq Na\right) = \Pr(\hat{P}_{\mathbf{X}} \in \Gamma)$$

サノフの定理より、この指数部は

$$-\inf_{q \in \Gamma^\circ} D((1-q, q) \parallel (1-p, p)) = -\inf_{q \in \Gamma} D((1-q, q) \parallel (1-p, p))$$

である。

$$\begin{aligned} \inf_{q \in \Gamma} D((1-q, q) \parallel (1-p, p)) &= \inf_{q \geq a} (1-q) \log \frac{1-q}{1-p} + q \log \frac{q}{p} \\ &= \begin{cases} 0 & \text{if } a \leq p \\ (1-a) \log \frac{1-a}{1-p} + a \log \frac{a}{p} & \text{otherwise.} \end{cases} \end{aligned}$$

これはクラメールの定理で得られるレート関数  $I_X(a)$  と等しい。



## 課題

- ▶  $p = (0.1, 0.2, 0.7)$ ,  $q = (0.3, 0.6, 0.1)$  について  $D(q \parallel p)$  と  $D(p \parallel q)$  を求めよ。