確率・統計基礎: ベイズ推定

森 立平

用語

- $x \in A$: データ、知っているもの (今日は離散と仮定するが、 本質的な仮定ではない)
- ▶ $s \in B$: パラメータ、推定したいもの (今日は離散の場合を考える。連続のときは θ という記号を使うことが多い)
- ▶ Pr(S = s): 事前確率
- ▶ Pr(X = x | S = s): 尤度
- ▶ Pr(S = s | X = x): 事後確率

最大事後確率推定

問題

確率分布 $\Pr(S = s, X = x)$ が既知である。与えられた $x \in A$ から $s \in B$ を推定したい。推定関数 $E: A \to B$ の平均誤り確率は $\Pr(E(X) \neq S)$ で定義される。

$$Pr(E(X) \neq S) = 1 - Pr(S = E(X))$$

$$= 1 - \sum_{x \in A} Pr(X = x) Pr(S = E(X) \mid X = x)$$

$$= 1 - \sum_{x \in A} Pr(X = x) Pr(S = E(x) \mid X = x)$$

これを最小化したいので $E(x) = \underset{s}{\operatorname{arg\,max}} \Pr(S = s \mid X = x)$ とするのが 最適である。これを最大事後確率推定という。

最尤推定

最大事後確率推定 (Maximum a posteriori probability estimation)

$$E_{\text{MAP}}(x) \coloneqq \underset{s}{\text{arg max Pr}(S = s \mid X = x)}$$

平均誤り確率を最小化する。事前分布を知らないと使えない。

最尤推定 (Maximum likelihood estimation)

$$E_{\mathrm{ML}}(x) \coloneqq \operatorname*{arg\,max}_{s} \Pr(X = x \mid S = s)$$

平均誤り確率については何も言えない。事前分布を知らなくても使える。

事前分布が一様分布
$$P(S=s)=\frac{1}{|B|}$$
 のとき、

$$\arg \max_{s} \Pr(S = s \mid X = x) = \arg \max_{s} \frac{\Pr(S = s, X = x)}{\Pr(X = x)}$$

$$= \arg \max_{s} \Pr(S = s, X = x)$$

$$= \arg \max_{s} \Pr(S = s) \Pr(X = x \mid S = s)$$

$$= \arg \max_{s} \Pr(X = x \mid S = s)$$

最大事後確率推定と最尤推定は等しい。

二値の推定

 $B = \{0,1\}$ の状況を考える。以下のように $p_0(x)$, $p_1(x)$ を定義する。

$$p_0(x) := \Pr(X = x \mid S = 0)$$

 $p_1(x) := \Pr(X = x \mid S = 1)$

 $\Pr(S=0)=\lambda$, $\Pr(S=1)=1-\lambda$ とする。最大事後確率推定では $\lambda p_0(x)$ と $(1-\lambda)p_1(x)$ を比較して、前者 (もしくは後者) が大きい場合 0(もしくは 1) と推定する。このとき

$$\begin{split} &\Pr(E_{\text{MAP}}(X) = S) - \Pr(E_{\text{MAP}}(X) \neq S) \\ &= \sum_{s} \Pr(S = s) \Pr(E_{\text{MAP}}(X) = S \mid S = s) - \sum_{s} \Pr(S = s) \Pr(E_{\text{MAP}}(X) \neq S \mid S = s) \\ &= \sum_{x \in E_{\text{MAP}}^{-1}(0)} \lambda p_0(x) + \sum_{x \in E_{\text{MAP}}^{-1}(1)} (1 - \lambda) p_1(x) \\ &- \left(\sum_{x \in E_{\text{MAP}}^{-1}(1)} \lambda p_0(x) + \sum_{x \in E_{\text{MAP}}^{-1}(0)} (1 - \lambda) p_1(x) \right) \\ &= \sum_{x \in E_{\text{MAP}}^{-1}(0)} (\lambda p_0(x) - (1 - \lambda) p_1(x)) - \left(\sum_{x \in E_{\text{MAP}}^{-1}(0)} (\lambda p_0(x) - (1 - \lambda) p_1(x)) \right) \\ &= \sum_{x \in E_{\text{MAP}}^{-1}(0)} |\lambda p_0(x) - (1 - \lambda) p_1(x)| \end{split}$$

全変動距離

最小誤り確率は

$$\frac{1-\sum_{x\in A}|\lambda p_0(x)-(1-\lambda)p_1(x)|}{2}.$$

特に $\lambda = 1/2$ のとき、

$$\frac{1 - \frac{1}{2} \sum_{x \in A} |p_0(x) - p_1(x)|}{2}.$$

Definition (全変動距離 (Total variation distance))

 $p, q \in \mathcal{P}$ についてその全変動距離 $d_{TV}(p, q)$ を以下で定義する。

$$d_{\text{TV}}(p, q) \coloneqq \frac{1}{2} \sum_{x \in A} |p(x) - q(x)|.$$

平均誤り確率の漸近的挙動

二種類あるコインの片方を選んで独立に何回も投げる。どちらのコイン を選んだのか推定したい。

$$Pr(\mathbf{X} = \mathbf{x}, S = s) = Pr(S = s) \prod_{k=1}^{N} Pr(X_i = x_i \mid S = s)$$

誤り確率は

$$\sum_{\mathbf{x} \in A^N} \left| \lambda \prod_k p_0(x_k) - (1 - \lambda) \prod_k p_1(x_k) \right|.$$

から定まるが、これを見ても $N\to\infty$ の挙動はよく分からない。 $p(s)\coloneqq\Pr(S=s),\;p(x\mid s)\coloneqq\Pr(X=x\mid S=s),\;p(\mathbf{x}\mid s)\coloneqq\prod_k p(x_k\mid s)$ とすると、

$$\begin{split} \Pr(E_{\text{MAP}}(\mathbf{X}) \neq S) &= \Pr\left(p(S)p(\mathbf{X} \mid S) \leq p(\overline{S})p(\mathbf{X} \mid \overline{S})\right) \\ &= \Pr\left(\sum_{k} \log \frac{p(X_k \mid S)}{p(X_k \mid \overline{S})} \leq \log \frac{p(\overline{S})}{p(S)}\right). \end{split}$$

(不等号が等号の場合は 1/2 の確率でエラーになるが、簡単のためそれはエラーと数えることにする)。

平均誤り確率の漸近的挙動

$$\Pr\left(\sum_{k} \log \frac{p(X_k \mid S)}{p(X_k \mid \overline{S})} \le \log \frac{p(\overline{S})}{p(S)}\right) = \lambda \Pr\left(\sum_{k} \log \frac{p(X_k \mid 0)}{p(X_k \mid 1)} \le \log \frac{1 - \lambda}{\lambda} \mid S = 0\right) + (1 - \lambda) \Pr\left(\sum_{k} \log \frac{p(X_k \mid 1)}{p(X_k \mid 0)} \le \log \frac{\lambda}{1 - \lambda} \mid S = 1\right)$$

この確率はクラメールの定理で漸近評価できる。

課題

$$A = \{0, 1, 2\}, B = \{0, 1\} \succeq \cup$$

$$\Pr(S = 0) = 1/4$$
 $\Pr(S = 1) = 3/4$
 $\Pr(X = 0 \mid S = 0) = 1/6$ $\Pr(X = 1 \mid S = 0) = 2/6$ $\Pr(X = 2 \mid S = 0) = 3/6$
 $\Pr(X = 0 \mid S = 1) = 3/6$ $\Pr(X = 1 \mid S = 1) = 1/6$ $\Pr(X = 2 \mid S = 1) = 2/6$

とするとき、以下の問に答えよ。

- 1. Xから S を最大事後確率推定する関数 $E_{\text{MAP}}: A \to B$ と最尤推定する関数 $E_{\text{MI}}: A \to B$ をもとめよ。
- 2. XからSを最大事後確率推定した場合の平均誤り確率をもとめよ。
- 3. XからSを最尤推定した場合の平均誤り確率をもとめよ。